

Сегодня поговорим про сложность алгоритмов.

Для того, чтобы выбрать подходящий для решения задачи алгоритм, нужно уметь оценивать скорость его работы, объём требуемой памяти и т.д. Следует помнить, что не всегда самый быстрый алгоритм является самым лучшим — обычно машинное время сейчас стоит дешевле времени программиста, поэтому часто имеет смысл выбрать не самый быстрый/потребляющий мало памяти алгоритм, а тот, который быстрее и проще написать. Зато если предполагается, что программа будет выполняться часто, стоит использовать эффективный алгоритм, даже если он более сложный. В некоторых случаях эффективные, но сложные алгоритмы могут быть нежелательными, если готовые программы будут поддерживать лица, не участвующие в написании этих программ.

Сложность бывает не только вычислительная, но и ёмкостная — сколько дополнительной памяти требует программа. Причем часто бывает так, что одна переводится в другую. Например, если предварительно нафигачить в памяти здоровенную таблицу со значениями некоторой сложно вычислимой функции, то эти значения вообще можно будет получать за константное время. Но с ёмкостной сложностью более-менее понятно, что считать, так что поговорим про вычислительную.

Само измерение времени выполнения алгоритма — не такая простая задача. Во-первых, его нельзя мерять в секундах, минутах и т.д. — время зависит от конкретной машины, на которой выполняется программа, реализующая алгоритм, от компилятора и т.д. Во-вторых, время зависит от входных данных (от них самих или их количества). Поэтому время выполнения обычно считают в неких условных единицах — в элементарных шагах алгоритма, или в количестве операций некой абстрактной машины, например, машины Тьюринга (ну или у Кнута была некая идеальная машина, которую он использовал для оценки времени работы). При этом время выполнения обычно считают как функцию объёма входных данных (например, для алгоритмов сортировки это число элементов в сортируемом массиве, для численных алгоритмов — длина двоичного представления числа и т.п.). Поскольку работа алгоритма зависит и от самих входных данных, можно говорить о времени выполнения в наилучшем, среднем и наихудшем случае. Например, некоторые алгоритмы сортировки работают на уже отсортированном массиве за число операций, линейно зависящее от размера массива.

Собственно, точная оценка времени выполнения алгоритма обычно является сложной математической задачей и никому в реальной жизни нафиг не нужна. Обычно используются асимптотическая сложность — приблизительная оценка скорости роста функции времени выполнения в зависимости от размера входных данных, для этого используется O-символика (собственно, с символами O вы ещё не раз встретитесь на матане).

$$f(n) \in O(g(n)) \Leftrightarrow \exists(C > 0), n_0 : \forall(n > n_0) f(n) \leq Cg(n)$$

Т.е.  $f$  ограничена сверху функцией  $g$  с точностью до постоянного множителя.

Например,  $f(n) = O(n^2)$  —  $f(n)$  растёт не быстрее, чем  $n^2$  с любой константой. Это имеет самое прямое отношение к алгоритмам, поскольку степень роста функции времени выполнения показывает, какого размера задачи этим алгоритмом имеет смысл решать. Например, алгоритм, имеющий степень роста  $O(n^2)$  лучше алгоритма, имеющего степень роста  $O(n^3)$ , но не всегда. Алгоритмы с экспоненциальной трудоёмкостью лучше на компах не реализовывать вовсе. Ещё бывают полезны

символы омега (то же самое, только  $Sg \leq f$ ) и тета (когда и  $O$ , и омега). Также бывают  $o$ -малое и  $\omega$ -малое, но это уже к матанщикам, нам такие детали ни к чему.

Обозначение	Граница	Рост
(Тета) $\Theta$	Нижняя и верхняя границы, точная оценка	Равно
( $O$ - большое) $O$	Верхняя граница, точная оценка неизвестна	Меньше или равно
( $o$ - малое) $o$	Верхняя граница, не точная оценка	Меньше
(Омега - большое) $\Omega$	Нижняя граница, точная оценка неизвестна	Больше или равно
(Омега - малое) $\omega$	Нижняя граница, не точная оценка	Больше

Алгоритм	Эффективность
$o(n)$	$< n$
$O(n)$	$\leq n$
$\Theta(n)$	$= n$
$\Omega(n)$	$\geq n$
$\omega(n)$	$> n$

Феерический пример из википедии: «пропылесосить ковер» требует время, линейно зависящее от его площади ( $\Theta(A)$ ), то есть на ковер, площадь которого больше в два раза, уйдет в два раза больше времени. Соответственно, при увеличении площади ковра в сто тысяч раз, объем работы увеличивается строго пропорционально в сто тысяч раз, и т. п.

Собственно, вычисление трудоёмкости задачи использует следующие правила: если  $P1$  и  $P2$  выполняются за времена  $T1(n)$  и  $T2(n)$ , имеющие порядок  $O(f(n))$  и  $O(g(n))$ , то последовательно выполненные эти фрагменты выполняются за время порядка  $O(\max(f(n), g(n)))$ . В частности, из этого следует, что  $O(n^2 + n) = O(n^2)$ . Произведение двух функций имеет порядок произведения - если  $T1(n)$  и  $T2(n)$  имеют порядок роста  $O(f(n))$  и  $O(g(n))$ , то  $T1(n)T2(n)$  имеет порядок  $O(f(n)g(n))$  - это полезно при анализе циклов.

Например, рассмотрим пузырьрёк:

```
for (int i=0; i < n; i++)
    for (int j=n; j > i; j--)
        if (a[j-1] > a[j])
            swap(a[j-1], a[j]);
```

`swap()` не зависит от размера входного массива и выполняется за  $O(1)$ . `if` выполняется за  $O(1)$ , `if` и его содержимое - за  $O(1 + 1) = O(1)$ , хотя мы и не знаем,

выполнится содержимое или нет (мы ищем время выполнения в худшем случае). Время выполнения внутреннего цикла - сумма времён выполнения его содержимого,  $n - i$  раз, так что  $O((n - i) * 1) = O(n - i)$ .

Внешний цикл - сумма по  $i$  от 1 до  $(n - 1)$   $n - i = n(n-1)/2 = n^2/2 + n/2$ , итого  $O(n^2)$ . Бывают сортировки с временем выполнения  $O(n \log n)$ , это *qsort*, который вам надо было реализовать дома в прошлой работе, или *heapsort*, который в текущей. Быстрее сортировок, не использующих информацию о числах в массиве, не бывает. Бывает сортировка за  $O(n)$  - поразрядная, но она использует знания о числах. Для сравнения, натуральный логарифм от миллиона — чуть меньше 14, двоичный от ста тысяч — примерно 17.

Программы с рекурсивными процедурами оценивать несколько интереснее: нужно получить рекуррентное соотношение времён выполнения процедуры. Например, факториал:

```
int recFactorial(int a)
{
    if (a <= 1)
        return 1;
    else
        return a * recFactorial(a - 1);
}
```

$T(n) = c + T(n-1)$  при  $n > 1$ , и  $d$ , при  $n \leq 1$ .

$T(n) = c + T(n-1) = 2c + T(n-2) = \dots = i*c + T(n-i) = \dots = (n-1)*c + T(1) = (n-1)*c + d$ .

Следовательно,  $T(n)$  имеет порядок  $O(n)$ .

Ещё интересным примером является задача вычисления  $n$ -го числа Фибоначчи:

$F_n = F_{n-2} + F_{n-1}$ ,  $F_0 = 1$ ,  $F_1 = 1$

$F = 1, 1, 2, 3, 5, 8, 13, 21, \dots$

Рекурсивное решение имеет трудоёмкость  $2^n$ :

```
long fibonacci(int n)
{
    if (n == 0 || n == 1)
        return 1;
    else
        return fib(n - 2) + fib(n - 1);
}
```

Итеративное -  $O(n)$ :

```
long fibonacciIterative(int n)
{
    int prev = 1;
    int curr = 1;
    for (int i = 2; i <= n; ++i)
    {
        int temp = prev + curr;
        prev = curr;
```

```

        curr = temp;
    }
    return curr;
}

```

А ещё можно считать Фибоначчи так:

$$\begin{matrix} F_{n+1} & F_n & = & \begin{vmatrix} 1 & 1 \\ 1 & 0 \end{vmatrix}^n \\ F_n & F_{n-1} & & \end{matrix}$$

Доказательство по индукции, оставим его в качестве упражнения желающим.

Еще можно применить яростный матан прямоком из ада и получить формулу для выражения чисел Фибоначчи через золотое сечение (формула Бине):


$$f_n = \frac{1}{\sqrt{5}} \left[ \left( \frac{1 + \sqrt{5}}{2} \right)^n - \left( \frac{1 - \sqrt{5}}{2} \right)^n \right].$$

Хоть тут будет и логарифмическая сложность, однако, тут видимо будет более 9000 ошибок округления, так что применение этой формулы для программистов довольно сомнительно.

Рассмотрим четыре алгоритма решения одной и той же задачи, имеющие логарифмическую, линейную, квадратичную и экспоненциальную сложности соответственно. Предположим, что второй из этих алгоритмов требует для своего выполнения на некотором компьютере при значении параметра  $n=10^3$  ровно одну минуту времени. Тогда времена выполнения всех этих четырех алгоритмов на том же компьютере при различных значениях параметра будут примерно такими:

Сложность алгоритма	$n = 10$	$n = 10^3$	$n = 10^6$
$\log n$	0.2 сек.	0.6 сек.	1.2 сек.
$n$	0.6 сек.	1 мин.	16.6 час.
$n^2$	6 сек.	16.6 час.	1902 года
$2^n$	1 мин.	$10^{295}$ лет	$10^{300000}$ лет

Еще одна показательная картинка:



В следующей таблице приведено сравнение алгоритмов сортировки.

Алгоритм	Структура данных	Временная сложность			Вспомогательные данные
		Лучшее	В среднем	В худшем	В худшем
Быстрая сортировка	Массив	$O(n \log(n))$	$O(n \log(n))$	$O(n^2)$	$O(n)$
Сортировка слиянием	Массив	$O(n \log(n))$	$O(n \log(n))$	$O(n \log(n))$	$O(n)$
Пирамидальная сортировка	Массив	$O(n \log(n))$	$O(n \log(n))$	$O(n \log(n))$	$O(1)$
Пузырьковая сортировка	Массив	$O(n)$	$O(n^2)$	$O(n^2)$	$O(1)$
Сортировка вставками	Массив	$O(n)$	$O(n^2)$	$O(n^2)$	$O(1)$
Сортировка выбором	Массив	$O(n^2)$	$O(n^2)$	$O(n^2)$	$O(1)$
Блочная сортировка	Массив	$O(n+k)$	$O(n+k)$	$O(n^2)$	$O(nk)$
Поразрядная сортировка	Массив	$O(nk)$	$O(nk)$	$O(nk)$	$O(n+k)$

Более интересные примеры (ответы приводятся, доказательство оставляю в качестве упражнения).

```
for (int i = 1; i*i <= N; i = i*4)
    sum++;
```

Тело цикла будет выполнено  $\log_4(N^{1/2})$  раз. Таким образом, сложность  $O(\log n)$ .

```

int sum = 0;
for (int i = 1; i <= N; i++)
    for (int j = 1; j <= N; j += i)
        sum++;

```

Внутренняя часть циклов выполнится  $N + N/2 + N/3 + N/4 + \dots + 1 \sim N \ln N$  раз. (Используется разложение  $1 + 1/2 + 1/3 + \dots + 1/N \sim \ln N$ ). Собственно, сложность получается  $O(n \cdot \log(n))$ .

```

int sum = 0;
for (int i = 1; i*i <= N; i = i*4)
    for (int j = 0; j < i; j++)
        sum++;

```

Тело внутреннего цикла выполнится  $1 + 4 + 16 + 64 + \dots + \sqrt{N} \sim 4/3 \sqrt{N}$  раз. Сложность —  $O(\sqrt{n})$ .